

Lab04_Mariuci

Sarah Mariuci

Lab 04 - Importação de Dados Retangulares - Excel

Q1. Carregue os pacotes readxl e tidyverse.

```
#install.packages('readxl')
#install.packages('tidyverse')
library(readxl)
library(tidyverse)
```

```
— Attaching core tidyverse packages — tidyverse 2.0.0
—
✓ dplyr      1.2.1    ✓ readr      2.2.0
✓ forcats    1.0.1    ✓ stringr    1.6.0
✓ ggplot2    4.0.3    ✓ tibble     3.3.1
✓ lubridate  1.9.5    ✓ tidyr      1.3.2
✓ purrr      1.2.2
— Conflicts — tidyverse_conflicts()
—
* dplyr::filter() masks stats::filter()
* dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all
conflicts to become errors
```

Q2. Crie uma variável chamada fname que contenha o caminho para o arquivo WDIEXCEL.xlsx, disponível no seu diretório de dados. Confirme que o R identifica a existência do arquivo utilizando o comando file.exists

```
fname <- "Data/WDIEXCEL.xlsx"
file.exists(fname)
```

```
[1] TRUE
```

Q3. Leia a planilha “Country” e armazene no objeto countries.

```
countries <- read_excel(fname, sheet = "Country")
```

Q4. Mantenha apenas os registros de 5 países (Brasil e outros 4 de sua escolha).

```

codigos_escolhidos <- c("BRA", "ARG", "USA", "AGO", "PRT")
países <- countries |>
  filter(`Country Code` %in% codigos_escolhidos)
países |>
  select('Short Name')

```

```

# A tibble: 5 × 1
  `Short Name`
  <chr>
1 Angola
2 Argentina
3 Brazil
4 Portugal
5 United States

```

Q5. Leia a planilha “Data” e armazene no objeto WDI.

```

# Nota de reprodutibilidade: A planilha original em Excel (.xlsx) excede o
# limite de 1GB de RAM do Posit Cloud. Para evitar travamentos, a aba "Data" foi
# convertida para CSV ("WDICSV.csv"), permitindo uma leitura rápida e idêntica
# dos dados.
WDI <- read_csv("data/WDICSV.csv")

library(tidyverse)

# 1. Função callback para filtrar e selecionar colunas em cada lote
processa_WDI <- function(input, pos) {
  input |>
    filter(`Country Code` %in% países$`Country Code`) |>
    select(
      `Country Code`,
      `Indicator Code`,
      `1960`:`2018`
    )
}

# 2. Leitura otimizada por blocos (chunks) do arquivo CSV
WDI <- read_csv_chunked(
  "Data/WDICSV.csv",
  callback = DataFrameCallback$new(processa_WDI),
  chunk_size = 100000,
  show_col_types = FALSE
)

# 3. Visualiza o resultado
head(WDI)

```

```
# A tibble: 6 × 61
  `Country Code` `Indicator Code` `1960` `1961` `1962` `1963` `1964` `1965`
  <chr>          <chr>          <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 AGO           EG.CFT.ACCS.ZS      NA     NA     NA     NA     NA     NA
2 AGO           EG.CFT.ACCS.RU.ZS   NA     NA     NA     NA     NA     NA
3 AGO           EG.CFT.ACCS.UR.ZS   NA     NA     NA     NA     NA     NA
4 AGO           EG.ELC.ACCS.ZS      NA     NA     NA     NA     NA     NA
5 AGO           EG.ELC.ACCS.RU.ZS   NA     NA     NA     NA     NA     NA
6 AGO           EG.ELC.ACCS.UR.ZS   NA     NA     NA     NA     NA     NA
# i 53 more variables: `1966` <dbl>, `1967` <dbl>, `1968` <dbl>, `1969` <dbl>,
# `1970` <dbl>, `1971` <dbl>, `1972` <dbl>, `1973` <dbl>, `1974` <dbl>,
# `1975` <dbl>, `1976` <dbl>, `1977` <dbl>, `1978` <dbl>, `1979` <dbl>,
# `1980` <dbl>, `1981` <dbl>, `1982` <dbl>, `1983` <dbl>, `1984` <dbl>,
# `1985` <dbl>, `1986` <dbl>, `1987` <dbl>, `1988` <dbl>, `1989` <dbl>,
# `1990` <dbl>, `1991` <dbl>, `1992` <dbl>, `1993` <dbl>, `1994` <dbl>,
# `1995` <dbl>, `1996` <dbl>, `1997` <dbl>, `1998` <dbl>, `1999` <dbl>, ...
```

Q6. Selecione apenas as colunas:

- Country Code
- Indicator Code
- E todos os anos de 1960-2018

```
WDI_selecionado <- WDI |>
  select('Country Code', 'Indicator Code', '1960':'2018')
```

Q7. Confirme se os dados em WDI estão em formato tidy. Se não estiverem, transforme-os para tal formato. Faça de forma que exista uma coluna referente ao ano chamada YEAR.

```
head(WDI_selecionado)
```

```
# A tibble: 6 × 61
  `Country Code` `Indicator Code` `1960` `1961` `1962` `1963` `1964` `1965`
  <chr>          <chr>          <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 AGO           EG.CFT.ACCS.ZS      NA     NA     NA     NA     NA     NA
2 AGO           EG.CFT.ACCS.RU.ZS   NA     NA     NA     NA     NA     NA
3 AGO           EG.CFT.ACCS.UR.ZS   NA     NA     NA     NA     NA     NA
4 AGO           EG.ELC.ACCS.ZS      NA     NA     NA     NA     NA     NA
5 AGO           EG.ELC.ACCS.RU.ZS   NA     NA     NA     NA     NA     NA
6 AGO           EG.ELC.ACCS.UR.ZS   NA     NA     NA     NA     NA     NA
# i 53 more variables: `1966` <dbl>, `1967` <dbl>, `1968` <dbl>, `1969` <dbl>,
# `1970` <dbl>, `1971` <dbl>, `1972` <dbl>, `1973` <dbl>, `1974` <dbl>,
# `1975` <dbl>, `1976` <dbl>, `1977` <dbl>, `1978` <dbl>, `1979` <dbl>,
# `1980` <dbl>, `1981` <dbl>, `1982` <dbl>, `1983` <dbl>, `1984` <dbl>,
# `1985` <dbl>, `1986` <dbl>, `1987` <dbl>, `1988` <dbl>, `1989` <dbl>,
```

```
# `1990` <dbl>, `1991` <dbl>, `1992` <dbl>, `1993` <dbl>, `1994` <dbl>,
# `1995` <dbl>, `1996` <dbl>, `1997` <dbl>, `1998` <dbl>, `1999` <dbl>, ...
```

```
WDI_tidy <- WDI_selecionado |>
  pivot_longer(
    cols = `1960`:`2018`,
    names_to = "YEAR",
    values_to = "VALUE",
    names_transform = list(YEAR = as.integer)
  )
```

Q8. Confirme se a coluna referente ao ano está em formato inteiro.

```
is.integer(WDI_tidy$YEAR)
```

```
[1] TRUE
```

Q9. Para o objeto WDI, mantenha apenas os registros dos países listados em countries. Selecione as colunas:

- Country Code
- Short Name
- YEAR
- SP.DYN.CBRT.IN

```
WDI_filtrado <- WDI_tidy |>
  filter(`Indicator Code` == "SP.DYN.CBRT.IN") |>
  rename(SP.DYN.CBRT.IN = VALUE)

WDI_final <- WDI_filtrado |>
  inner_join(países, by = "Country Code") |>
  select(`Country Code`, `Short Name`, YEAR, SP.DYN.CBRT.IN)
```

Q10. Ordene o objeto de forma que, para cada país, as informações estejam ordenadas por ano.


```
WDI_ordenado <- WDI_final |>
  arrange(`Short Name`, YEAR)
```

Q11. Construa um gráfico de linhas, usando o pacote ggplot2, que tenha no eixo X a variável YEAR, no eixo Y a variável SP.DYN.CBRT.IN e que cada linha corresponda a um país diferente.

```
library(ggplot2)

ggplot(WDI_ordenado, aes(x = YEAR, y = SP.DYN.CBRT.IN, color = `Short Name`,
```

```
group = `Short Name`)) +
  geom_line(linewidth = 1) +
  geom_point(size = 1.5, alpha = 0.8) +
  labs(
    title = "Evolução da Taxa Bruta de Natalidade (1960-2018)",
    subtitle = "Comparativo temporal entre os 5 países selecionados",
    x = "Ano (YEAR)",
    y = "Taxa de Natalidade (SP.DYN.CBRT.IN)",
    color = "País"
  ) +
  theme_minimal()
```



Horário de conclusão

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-09-09 16:49:23 -03"
```